

# Python задание 6: регрессия и байесовские вероятности

## 1 Модель линейной регрессии

Пусть у нас есть набор из  $n$  кортежей вещественных чисел  $\{(y_i; x_{i1}, \dots, x_{ik})\}_{i=1}^n$ , где  $x_{ij}$  считаются независимыми переменными, а  $y_i$  — зависимой переменной. Нашей целью будет научиться, используя этот набор данных, предсказывать  $y$ -и по новым  $x$ -ам.

Модель линейной регрессии предполагает, что  $y$ -и получаются как некоторая линейная комбинация  $x$ -ов:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i.$$

В этой формуле

- $\beta_0, \beta_1, \dots, \beta_k$  — неизвестные, но постоянные коэффициенты (константы), общие для всех  $\{(y_i; x_{i1}, \dots, x_{ik})\}_{i=1}^n$ .
- $\{\varepsilon\}_{i=1}^n$  представляют собой ошибки модели. Они необходимы потому, что мы не можем предполагать, что наши данные будут находиться в точной линейной зависимости. Если бы это было так, то у нас бы стояла обычная задача решения системы уравнений. Полагая, что  $\{\varepsilon\}_{i=1}^n$  также являются суммой вкладов от множества других, неизвестных нам факторов, разумно будет предположить, что они имеют нормальное распределение  $N_{0, \sigma^2}$  с неизвестной дисперсией.

Заметим, что, так как  $\beta_0, \beta_1, \dots, \beta_k$  и  $\{(x_{i1}, \dots, x_{ik})\}_{i=1}^n$  — константы, то каждый  $y_i$  можно считать нормальной случайной величиной со средним значением  $\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik}$  и дисперсией  $\sigma^2$ .

Оказывается, эти уравнения очень удобно переписать в матричной форме

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

где:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}.$$

В таком случае, при выполнении ряда естественных условий, оптимальные коэффициенты  $\hat{\beta}$  можно выразить как:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

где “крышечка” подчеркивает что это оценка, а не реальные  $\beta$ .

После того, как мы нашли приближённые коэффициенты  $\hat{\beta}$ , мы можем получить предсказания  $\hat{\mathbf{y}}$  по  $x$ -ам из нашей выборки:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}.$$

Эти  $\hat{y}$ -и содержат приближение линейной части нашей модели, зависящей от  $x$ -ов, но они не включают в себя отклонения от прочих факторов, представленные ошибками  $\{\varepsilon_i\}_{i=1}^n$ . Поэтому мы также можем получить приближения для этих ошибок через:

$$\hat{\varepsilon}_i = y_i - \hat{y}_i.$$

## 1.1 Задание № 1

В этом и во всех последующих заданиях используйте приложенный стандартный набор данных о ценах на дома в зависимости от различных факторов.

Выполните следующие шаги:

1. Исключите сильно коррелированные независимые переменные. Под «слишком высокой» корреляцией можно понимать абсолютное значение коэффициента корреляции выше 0.9. Это поможет избежать проблемы мультиколлинеарности в модели.
2. Преобразуйте категориальные переменные в числовой формат при помощи кодирования фиктивными переменными (также известного как «одноразрядное кодирование» или one-hot кодирование). Это позволит модели корректно работать с категориальной информацией.
3. Проверьте, не улучшится ли связь некоторых признаков с зависимой переменной при применении различных преобразований (например, логарифмирования или взятия квадратного корня). Если после преобразования переменной её корреляция с целевой переменной увеличивается, используйте преобразованную версию этой переменной.

## 1.2 Задание № 2

Напишите функцию, которая:

- Принимает на вход любой набор переменных в виде списка строк;
- Находит оценки для соответствующих параметров линейной регрессии;
- Находит приближения для ошибок линейной регрессии, а также оценку  $\hat{\sigma}^2$  их дисперсии  $\sigma^2$ .

## 2 Оценка значимости переменной

Хотя для предсказания значений  $y$  нам даётся  $k$  различных переменных  $\{(x_{i1}, \dots, x_{ik})\}_{i=1}^n$ , это не значит, что все они одинаково важны или даже вообще влияют на значения  $y$ . Мы попытаемся оставить только значимые переменные, проверяя для каждого коэффициента  $\beta_s$  следующие гипотезы:

$$\mathbf{H}_0 : \beta_s = 0;$$

$$\mathbf{H}_a : \beta_s \neq 0.$$

Выполнение  $\mathbf{H}_0$  означает, что соответствующая переменная не оказывает никакого влияния на значения  $y$ ,  $\mathbf{H}_a$  — наоборот, что это влияние есть.

Для этого мы посмотрим на построенные нами оценки  $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ . Так как они были получены как линейные комбинации  $y$ -ов:  $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ , то они и сами будут являться нормальными случайными величинами. Их средние значения равны реальным параметрам  $\beta_0, \beta_1, \dots, \beta_k$ . А их дисперсии можно получить из матрицы ковариации  $\hat{\beta}$ :

$$\begin{pmatrix} \mathbb{D}(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \cdots & \text{Cov}(\hat{\beta}_0, \hat{\beta}_k) \\ \text{Cov}(\hat{\beta}_1, \hat{\beta}_0) & \mathbb{D}(\hat{\beta}_1) & \cdots & \text{Cov}(\hat{\beta}_1, \hat{\beta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(\hat{\beta}_k, \hat{\beta}_0) & \text{Cov}(\hat{\beta}_k, \hat{\beta}_1) & \cdots & \mathbb{D}(\hat{\beta}_k) \end{pmatrix},$$

которая, оказывается, равна  $\sigma^2(\mathbf{X}^T \mathbf{X})^{-1}$ .

### 2.1 Задание № 3

Напишите функцию, которая, по обученной модели линейной регрессии, проводит тест на значимость любого указанного ей коэффициента  $\hat{\beta}_s$ . Для этого:

- Найдите оценку дисперсии  $\hat{\beta}_s$ , используя вместо  $\sigma^2$  оценку регрессионных ошибок из предыдущего задания;
- Найдите стандартизацию коэффициента  $\hat{\beta}_s^{(st)}$  при условии выполнения основной гипотезы  $\mathbf{H}_0$ ;
- Предполагая, что стандартизация  $\hat{\beta}_s^{(st)}$  имеет приблизительно стандартное нормальное распределение и что более “экстремальными” (более указывающими на альтернативную гипотезу) значениями являются большие по модулю значения, найдите p-value для этого теста.

### 2.2 Отбор переменных

Произведите отбор наиболее значимых переменных с помощью процедуры *backwards elimination*:

1. Сначала обучите модель используя все доступные переменные;

2. Проведите тест на значимость для каждого коэффициента и найдите соответствующее ему  $p$ -value;
3. Если все  $p$ -values оказались меньше 0.05, то алгоритм завершает работу. Иначе исключается переменная с наибольшим значением  $p$ -value, модель обучается заново с нуля и мы повторяем алгоритм с **шага 2**.

Заметим, что для категориальных переменных нельзя выкидывать отдельные категории — их значимость оценивается по их “лучшей” категории и исключаются из алгоритма все категории сразу.

### 3 Байесовская оценка вероятности продажи

В этом задании нас будет интересовать не сама цена, а факт продажи. В таблице данных есть бинарный признак **Sold**, который принимает значение 1, если дом был продан, и 0, если нет. Будем считать, что внутри каждой фиксированной подгруппы домов случайная величина **Sold** имеет распределение Бернулли  $B_p$  с некоторым неизвестным параметром  $p \in [0, 1]$ , который интерпретируем как вероятность продажи дома из этой подгруппы.

Мы будем использовать байесовский взгляд на задачу: нас интересует не просто одна оценка вероятности  $p$ , а её распределение.

#### 3.1 Задание № 4

Напишите код на Python, который работает с исходным набором данных о домах и реализует следующую идею.

Разделите дома по типу водоёма в признаке **waterbody** (значения **None**, **River**, **Lake**, **Lake and River**).

Пользователь должен задать своё предположение о вероятности продажи дома в каждой группе (априорное математическое ожидание  $p$ ), а также степень «неуверенности» в этом предположении (априорное стандартное отклонение). Считаем, что априор для  $p$  задаётся бета-распределением. Используя исходный априор и данные по каждой подгруппе, для каждой группы найдите апостериорное распределение  $p$  и выведите его математическое ожидание и стандартное отклонение. После этого сравните группы между собой: где вероятность продажи выше, где ниже, и как сильно изменилась неопределённость по сравнению с априором.

Далее нужно показать, как выглядят последовательные байесовские обновления при объединении групп. Начните с априора по предположениям пользователя о продаже домов в группе **None** и обновите его по данным этой группы, получив первый апостериор. Затем возьмите этот апостериор как новый априор и обновите его по данным второй группы, снова посчитав апостериорные среднее и стандартное отклонение. Продолжайте так в выбранном порядке, шаг за шагом объединяя группы и отслеживая, как меняются параметры распределения  $p$  после каждого обновления.

Нарисуйте графики исходного априора, заданного пользователем, и всех полученных после обновлений апостериоров, чтобы было видно, как распределение постепенно уточняется под воздействием данных.