

Задание 1. Пропущенные значения и корреляции

[1.1] Используя функцию `multivariate_normal` из `numpy` с любым `random_state`, сгенерировать и зафиксировать датасет `dfS00`, в котором есть четыре количественных (недискретных) признака и 1 класс размером 1000 объектов, для одной пары признаков (A и B) которого задана корреляция $r=+0.9$, а остальные признаки не сопряжены друг с другом.

[1.2] Вывести в табличной форме статистику по датасету, включая

- Размерность всего датасета (объекты и признаки)
- Тип каждого признака
- Количество классов и объектов в каждом из классов
- Иные оценки выборки
- Число объектов с NaN по классам
- Число объектов с 0 по классам

[1.3] Выполнить 1D визуализацию датасета по каждому из признаков в форме `raincloud plot with jittering`, рядом с которым в виде `boxplot` отображены медианы, межквартильные размахи (IQR) и размахи (Range), с параметрами `boxplot`, которые можно заменять на другие оценки выборки.

[1.4] Выполнить 2D визуализацию датасета по всем парам выбранных переменных с использованием `scatterplot` с параметрами визуализации, регулируемые пользователем (цвета и толщины осей, число/шаг больших и малых рисок осей, сетка пространства, квадратность формы каждого рисунка, размер и тип шрифтов каждого типа подписей, отключаемость легенд и заглавий, прозрачность объектов), на которых отображены:

- на графиках разных пар признаков объекты классов разными по форме/цвету точками;
- на графиках с одной и той же парой переменных - диаграммы плотности распределения каждого класса по оси признака разными по цвету/прозрачности.

[1.5] Используя коэффициенты корреляции Пирсона и Спирмана, в форме `heat-map` таблицы оценить степень сопряженности пар признаков-переменных:

- на всем датасете
- в каждом отдельном классе датасета.

[1.6] На основе исходного датасета `dfS00` клонировать набор датасетов `dfSdXX`, в которых из исходного датасета случайным образом удалено значение заданного пользователем числа ячеек (0%, 1%, 2%, 5%, 10%, 20%, 50%, 80%). Для выбираемой пары признаков (исходно A+B) визуализировать каждый датасет `dfSdXX` как панно `mtn` рисунков `scatterplot`.

[1.7] На основе всех датасетов `dfSdXX` сгенерировать соответствующие датасеты `dfSdXXmed`, в которых пропуски заполнены медианой. Для выбираемой пары признаков (исходно A+B) визуализировать панно `mtn` рисунков `scatterplot` для всех `dfSdXXmed` и вывести как `heatmap` корреляции Пирсона как в пункте [1.5]

[1.8] На основе одного из датасетов `dfSdXX`, выбранного пользователем, сгенерировать соответствующие датасеты `dfSdXXname`, в котором пропуски заполнены следующими методами (`name`): медианами, kNN-заполнением, регрессионным заполнением, MICE-заполнением. Для `dfSd00`, выбранного `dfSdXX` и каждого из датасетов `dfSdXXname` вывести как `heatmap` корреляции Пирсона как в пункте [1.5], а также визуализировать две пары признаков, выбираемые пользователем (исходно A+B и C+D), как два панно `mtn` рисунков `scatterplot`.

[1.9] Для каждого из датасетов из пункта [1.8], включая исходный `dfSd00`, выполнить в форме `Upset plot` визуализацию (а) чисел объектов с пропущенными значениями для всех вариантов группировки пропусков по признакам, (б) чисел объектов с совпадающими значениями по признакам для всех вариантов группировки признаков.

[1.10]** На основе исходного датасета `dfS00` клонировать датасет `dfMNAR`, в котором для каждого объекта удалены все значения признаков C и D, которые меньше признаковой медианы. Выполнить для полученного датасета пункты [1.8] и [1.9].